



**TECNOLÓGICO
NACIONAL DE MÉXICO**



Inteligencia artificial

Profesor: ZURIEL DATHAN MORA FELIX

Tarea 6

Inv. Algoritmos de IA/Aprendizaje
automático y tabla comparativa

09/03/2025

Gomez Gastelum Diego Alejandro
Meza Manjarrez Marco Josue

ENFOQUE CONEXIONISTA

(REDES NEURONALES ARTIFICIALES)

El enfoque conexionista se basa en redes neuronales artificiales inspiradas en el cerebro humano. Este enfoque es capaz de aprender de datos y adaptarse a nuevas situaciones. Se ha utilizado con éxito en aplicaciones como el reconocimiento de imágenes y el procesamiento del lenguaje natural.

EJEMPLO: SISTEMAS DE RECOMENDACIONES

Las aplicaciones de inteligencia artificial (IA) en los sistemas de recomendación son las metodologías avanzadas que aprovechan las tecnologías de IA para mejorar el rendimiento de los motores de recomendación.

El recomendador basado en IA puede analizar conjuntos de datos complejos, aprendiendo del comportamiento, las preferencias y las interacciones del usuario para generar sugerencias de productos o contenido altamente precisas y personalizadas.

Las redes neuronales artificiales son especialmente relevantes en los sistemas de recomendación, donde su capacidad para manejar datos complejos y diversos las hace ideales para mejorar la experiencia del usuario. A diferencia de métodos tradicionales como el filtrado colaborativo, las RNA pueden incorporar tanto datos de retroalimentación como datos no convencionales, como la hora y estacionalidad de las interacciones, patrones de navegación del usuario y tendencias sociales externas, lo que permite identificar señales adicionales para personalizar las recomendaciones.

En el contexto de las recomendaciones, los Transformers pueden modelar secuencias de interacciones, como el historial de visualización de un usuario en una plataforma de streaming, para predecir el siguiente ítem que podría interesarle, esto es especialmente útil en aplicaciones como YouTube o Netflix.

El enfoque conexionista en los sistemas de recomendación utiliza redes neuronales artificiales para aprender patrones complejos y generar recomendaciones altamente personalizadas. Este paradigma permite a los sistemas adaptarse a las preferencias individuales de los usuarios y ofrecer sugerencias más relevantes y precisas. Su capacidad para manejar grandes volúmenes de datos y capturar relaciones no lineales lo convierte en una herramienta poderosa

Beneficios:

Las redes neuronales pueden capturar información de patrones complejos en el comportamiento del usuario

Aprenden embeddings () de los usuarios y de los ítems, donde los ítems y usuarios con gustos similares estén cerca entre sí

Limitaciones

Las redes neuronales requieren grandes cantidades de datos para entrenarse efectivamente, en los sistemas con pocos datos o nuevos usuarios/ítems el rendimiento puede llegar a ser limitado

Las redes neuronales son modelos de "caja negra", lo que significa que es difícil entender cómo llegaron a una recomendación específica usuarios con gustos similares estén cerca entre sí

Modelo Enfoque Computacional

El modelado computacional usa matemáticas, física e informática para simular sistemas complejos, ajustando variables y observando cómo afectan los resultados. Esto permite hacer predicciones y optimizar la investigación al realizar miles de simulaciones para seleccionar los experimentos físicos más prometedores. Además, los modelos actuales pueden estudiar sistemas biológicos en múltiples niveles —de moléculas a órganos—, lo que se conoce como modelado multiescala.

Ejemplo: pronóstico del clima

El pronóstico del clima usa modelos computacionales para predecir factores atmosféricos, protegiendo vidas, propiedades y cultivos. Además, ayuda a las empresas eléctricas a gestionar la demanda ante cambios climáticos extremos.

El pronóstico del clima es un proceso complejo que requiere modelar las interacciones de múltiples variables atmosféricas, como temperatura, presión, humedad y velocidad del viento. Estas observaciones se recopilan de estaciones, satélites y globos meteorológicos de todo el mundo, generando enormes volúmenes de datos que cambian constantemente.

Para predecir el estado futuro de la atmósfera, se identifican las variables relevantes y se establecen sus correlaciones. Luego, se utilizan ecuaciones diferenciales parciales no lineales (como las ecuaciones hidrodinámicas) para describir estas relaciones. Dado que resolver estas ecuaciones manualmente sería inviable, se discretizan con métodos numéricos, como diferencias finitas, y se implementan en programas que calculan soluciones aproximadas basadas en condiciones iniciales y datos de entrada.

Este enfoque se llama predicción meteorológica numérica, y los programas que ejecutan estos cálculos son modelos meteorológicos. Debido a la complejidad y magnitud de los cálculos, se utilizan supercomputadoras para procesar los datos y generar pronósticos precisos, lo que permite anticipar patrones climáticos y tomar decisiones cruciales para la sociedad.

Ventajas del enfoque computacional:

- **Precisión y rapidez:** Permite analizar grandes volúmenes de datos y hacer predicciones complejas en poco tiempo.
- **Simulación de escenarios:** Posibilita probar diferentes hipótesis sin experimentar directamente con el sistema real.
- **Automatización y optimización:** Los algoritmos aprenden y mejoran con el tiempo, optimizando las predicciones.

Limitaciones:

- **Requiere alta capacidad computacional:** Modelar fenómenos complejos exige supercomputadoras o clusters de alto rendimiento.
- **Sensibilidad a los datos de entrada:** Errores o falta de precisión en los datos pueden propagar inexactitudes en las predicciones.
- **Modelos simplificados:** A menudo, es necesario simplificar las ecuaciones o hacer aproximaciones, lo que puede limitar la fidelidad del modelo a la realidad.

Aprendizaje automático (Machine Learning)

Es una rama de la inteligencia artificial que permite a las computadoras aprender a partir de datos sin ser programadas explícitamente. Los algoritmos encuentran patrones en los datos, ajustan sus parámetros y hacen predicciones o decisiones basadas en la experiencia.

Etapas del aprendizaje automatico

1. Adquisición de datos

Esta es la fase inicial, donde se recopila la información que servirá para entrenar el modelo. Los datos pueden provenir de distintas fuentes:

- **Bases de datos** estructuradas o no estructuradas.
- **APIs o servicios web** que proveen datos en tiempo real.
- **Sensores o dispositivos IoT** que capturan datos físicos.
- **Web scraping** para extraer información de páginas web.

Objetivo: Obtener suficientes datos representativos para que el modelo aprenda patrones significativos.

2. Preprocesamiento de datos

Una vez que los datos están disponibles, es necesario limpiarlos y transformarlos para que sean útiles. Aquí se realizan varias tareas clave:

- **Limpieza de datos:** Eliminar duplicados, corregir errores o manejar valores nulos.
- **Normalización o escalado:** Ajustar los valores a un rango uniforme para evitar que ciertas variables dominen el aprendizaje.
- **Codificación de variables categóricas:** Convertir categorías en números para que los algoritmos puedan procesarlas.
- **División de los datos:** Separar los datos en conjuntos de entrenamiento, validación y prueba.

Objetivo: Dejar los datos listos para alimentar al modelo sin que la calidad de los datos afecte negativamente los resultados.

3. Entrenamiento del modelo

En esta etapa, los datos preprocesados se introducen en un algoritmo de aprendizaje para que encuentre patrones o relaciones. El modelo ajusta sus parámetros internos a través de múltiples iteraciones.

- **Algoritmos supervisados:** Usan datos etiquetados (con resultados conocidos) para aprender a hacer predicciones.
- **Algoritmos no supervisados:** Encuentran estructuras ocultas en los datos sin etiquetas (como agrupamientos).
- **Aprendizaje por refuerzo:** El modelo aprende a través de prueba y error, recibiendo recompensas o penalizaciones.

Objetivo: Ajustar los parámetros del modelo para minimizar el error y mejorar su capacidad de generalizar a nuevos datos.

4. Evaluación del modelo

Una vez entrenado, es esencial evaluar el rendimiento del modelo para asegurarse de que realmente aprende lo que se necesita. Se utilizan métricas específicas según el tipo de problema:

- **Precisión (accuracy):** Porcentaje de predicciones correctas.
- **Recall y precisión:** Métricas útiles para problemas con clases desbalanceadas.
- **Matriz de confusión:** Para analizar aciertos y errores más detalladamente.
- **Error cuadrático medio (MSE):** Para medir la magnitud del error en problemas de regresión.

Objetivo: Validar que el modelo no solo funciona bien con los datos de entrenamiento, sino que también se comporta correctamente con datos nuevos.

5. Implementación del modelo

Cuando el modelo pasa las pruebas de evaluación, se puede implementar en un entorno de producción para hacer predicciones en tiempo real o automatizar tareas. Esto implica:

- **Despliegue en la nube o en servidores locales.**
- **Creación de APIs o servicios web para consumir el modelo.**
- **Monitoreo continuo para detectar caídas de rendimiento o cambios en los datos (data drift).**

Objetivo: Utilizar el modelo para resolver problemas reales, aportando valor al negocio o al área de estudio.

Tabla Comparativa de similitudes y diferencias entre aprendizaje automático y el modelo cognitivo

SIMILITUDES

Aspectos	Modelo cognitivo	Aprendizaje automático
Basados en redes neuronales	Ambos utilizan unidades interconectadas (neuronas artificiales en ML y neuronas en la cognición) para procesar información	Aprenden patrones a partir de experiencias o datos
Aprendizaje a partir de la experiencia	En el modelo conexionista, el aprendizaje ocurre a través de la modificación de conexiones sinápticas	En aprendizaje automático, se ajustan pesos y parámetros en la red neuronal para minimizar errores
Procesamiento paralelo y distribuido	En el cerebro, la información se procesa en múltiples áreas simultáneamente	En redes neuronales, múltiples nodos procesan datos en paralelo para mejorar el rendimiento
Capacidad de generalización	Ambos pueden predecir o inferir información nueva basada en experiencias previas	Ejemplo: Un niño aprende a reconocer un gato → Una IA aprende a identificar gatos en imágenes

Diferencias

Aspecto	Modelo Cognitivo	Aprendizaje Automático
Propósito	Explicar cómo funciona la cognición humana	Crear modelos para resolver problemas computacionales
Aprendizaje	Modificación de conexiones entre neuronas	Ajuste de pesos mediante optimización matemática
Datos de entrada	Estímulos sensoriales del mundo real	Datos estructurados o no estructurados
Reglas de Aprendizaje	Basado en plasticidad neuronal y refuerzo biológico	Algoritmos como backpropagation y optimización por gradiente
Explicabilidad	No siempre claro cómo el cerebro toma decisiones	Aunque sigue siendo una "caja negra", en ML se pueden analizar pesos y activaciones

Referencias

https://www.nibib.nih.gov/sites/default/files/Computational_Modeling_Fact_Sheet_Spanish_v5_508.pdf

<https://www.earthdata.nasa.gov/>

<https://www.nibib.nih.gov/espanol/temas-cientificos/modelado-computacional>

http://repositoriodspace.unipamplona.edu.co/jspui/bitstream/20.500.12744/6003/1/Guillen_2017_TG.pdf

<https://www.ibm.com/mx-es/topics/weather-models>

<https://aws.amazon.com/es/what-is/machine-learning/>

<https://arxiv.org/abs/2105.11601>

<https://sistemasinformatica.istmo.tecnm.mx/cursos/inteligencia-artificial/2-representacion-del-conocimiento/2-2-paradigmas-de-la-inteligencia-artificial/>

<https://www.tensorflow.org/recommenders?hl=es>